Implementasi Aristektur DenseNet201 dengan Transfer Learning untuk Klasifikasi Kualitas Bawang Merah Berbasis Web

Salman Al Kafi[1], Miftahus Sholihin[1], M. Rosidi Zamroni[1]
[1]Program Studi Teknik Informatika, Fakultas Sains dan Teknologi, Universitas Islam Lamongan, Lamongan
e-mail: manruasegat@gmail.com

Abstrak

Kualitas bawang merah merupakan salah satu faktor penting yang memengaruhi nilai jual dan penerimaan produk di pasar. Proses penentuan kualitas bawang merah umumnya masih dilakukan secara manual berdasarkan pengamatan visual, sehingga rentan terhadap subjektivitas dan inkonsistensi hasil penilaian. Penelitian ini bertujuan untuk merancang dan mengimplementasikan sistem klasifikasi kualitas bawang merah berbasis web menggunakan arsitektur DenseNet201 dengan metode Transfer Learning serta mengevaluasi pengaruh variasi batch size terhadap performa model. Dataset yang digunakan terdiri dari 1.200 citra bawang merah yang terbagi ke dalam dua kelas, yaitu kualitas baik dan kualitas buruk. Tahapan penelitian meliputi pengumpulan data, preprocessing citra menggunakan Contrast Limited Adaptive Histogram Equalization (CLAHE) dan sharpening, pembagian dataset, pelatihan model menggunakan Transfer Learning DenseNet201, serta implementasi model pada sistem berbasis web menggunakan framework Laravel dan Flask. Pengujian dilakukan menggunakan tiga variasi batch size, yaitu 16, 32, dan 64. Hasil pelatihan menunjukkan bahwa seluruh konfigurasi mampu menghasilkan performa yang sangat baik, dengan akurasi validasi mencapai 99,44% pada akhir proses Fine-Tuning. Pada tahap pengujian, model dengan batch size 32 menghasilkan performa terbaik dengan akurasi sebesar 100%, precision sebesar 100%, recall sebesar 100%, dan F1-score sebesar 100%, serta nilai loss sebesar 0,0456. Selain itu, sistem yang dikembangkan mampu melakukan klasifikasi citra bawang merah secara otomatis melalui antarmuka web dengan waktu inferensi rata-rata 294 ms per citra. Hasil penelitian menunjukkan bahwa kombinasi DenseNet201 dan Transfer Learning merupakan pendekatan yang efektif untuk klasifikasi kualitas bawang merah serta berpotensi mendukung proses penilaian kualitas secara lebih cepat, konsisten, dan objektif.

Kata Kunci: DenseNet201, *Transfer Learning*, Klasifikasi Citra, Kualitas Bawang Merah, *Deep Learning.*

Abstract

Shallot quality is one of the important factors affecting product value and market acceptance. However, the quality assessment process is generally performed manually through visual inspection, making it prone to subjectivity and inconsistency. This study aims to design and implement a web-based shallot quality classification system using the DenseNet201 architecture with the Transfer Learning method and to evaluate the effect of batch size variations on model performance. The dataset consisted of 1,200 shallot images divided into two classes: good quality and poor quality. The research stages included data collection, image preprocessing using Contrast Limited Adaptive Histogram Equalization (CLAHE) and sharpening, dataset splitting, model training using DenseNet201 Transfer Learning, and system implementation using Laravel and Flask frameworks. Experiments were conducted using three batch size configurations: 16, 32, and 64. The training results showed that all configurations achieved excellent performance, with validation accuracy reaching 99.44% at the end of the fine-tuning stage. During testing, the model with a batch size of 32 achieved the best performance, obtaining 100% accuracy, 100% precision, 100% recall, 100% F1-score, and a loss value of 0.0456. Furthermore, the developed system was able to classify shallot images automatically through a web interface with an average inference time of 294 ms per image. The results demonstrate that the combination of DenseNet201 and Transfer Learning is an effective approach for shallot quality classification and has the potential to support faster, more consistent, and objective quality assessment processes.

Keywords*: DenseNet201, Transfer Learning, Image Classification, Shallot Quality, Deep Learning*.

1. PENDAHULUAN

Bawang merah (*Allium cepa var. aggregatum*) merupakan komoditas hortikultura strategis, namun rantai pasoknya masih menghadapi persoalan mendasar terkait standarisasi kualitas visual. Kendala

utama bermuara pada proses klasifikasi kualitas di lapangan yang sangat bergantung pada inspeksi visual manual yang subyektif, berkapasitas rendah, dan inkonsisten. Sebagai solusi, teknologi *deep learning* melalui arsitektur Convolutional Neural Network (CNN) DenseNet201 hadir melalui konsep konektivitas padat (*dense connectivity*) untuk mempertahankan fitur tekstur granular permukaan umbi bawang merah secara efisien tanpa rentan terhadap masalah *vanishing gradient.*

Untuk mengatasi keterbatasan data berlabel, strategi *transfer learning* diimplementasikan dengan memanfaatkan bobot pra-latih dari dataset masif *ImageNet*. Penelitian ini mengisi kesenjangan penelitian terdahulu dengan tidak hanya menguji performa model, tetapi juga mengintegrasikan DenseNet201 ke dalam antarmuka berbasis web *hybrid* agar teknologi sortasi otomatis ini dapat diakses secara praktis di lapangan tanpa memerlukan kompetensi teknis tinggi.

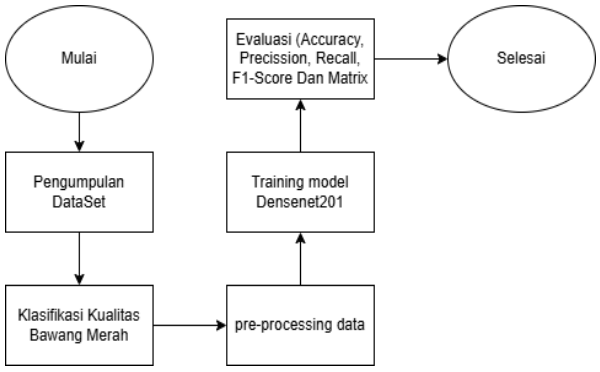
Tabel 1 Ringkasan penelitian terdahulu

NO	Penelitian	Metode	Domain	Akurasi
1.	Sandy dkk. (2025)	DenseNet201	Penyakit Daun Jagung	96,65%
2.	Izra dkk. (2025)	CNN	Bawang Merah	100%
3.	Darwis dkk. (2023)	K-Means	Bawang Merah	80%
4.	Aditya dkk. (2024)	Circularity *Image* Processing	Bawang Merah	66%
5.	Penelitian Ini	DenseNet201	Bawang Merah	100%(Batch Size 32)

2. METODE PENELITIAN

2.1 Desain dan Alur Penelitian

Penelitian menggunakan pendekatan kuantitatif terstruktur yang terdiri atas pengumpulan data set Bawang Merah, Klasifikasi Bawang Merah, *Pre-Processing* Data, *Training* Model DenseNet201, Evaluasi (*Accuracy, Precission, Recall, F1-Score dan Matrix*).



Gambar 1 Alur Penelitian

2.2 Dataset dan Pengumpulan Data

Total dataset terdiri dari 1.200 citra Bawang Merah. Dataset dibagi rata menjadi dua kelas: kualitas baik (600 citra) dan kualitas buruk (600 citra), yang kemudian dipecah menjadi porsi *training* (840 data), *validation* (180 data), dan *testing* (180 data).

Tabel 2 Split Data Bawang Merah

NO	Kelas	*Training*	*Validation*	*Testing*	Jumlah Data
1.	Baik	420	90	90	600
2.	Buruk	420	90	90	600
	Total	840	180	180	1200

2.3 Klasifikasi Kualitas Bawang Merah

Dalam penelitian ini, citra bawang merah diklasifikasikan secara visual ke dalam dua kategori utama, yaitu kelas baik yang ditandai dengan kondisi fisik segar, warna kulit normal, dan tanpa kerusakan, serta kelas buruk yang menunjukkan indikasi kerusakan seperti busuk, bertunas, berjamur, keriput, atau mengalami perubahan warna yang signifikan.

Tabel 3 Split Klasifikasi Kualitas Bawang Merah

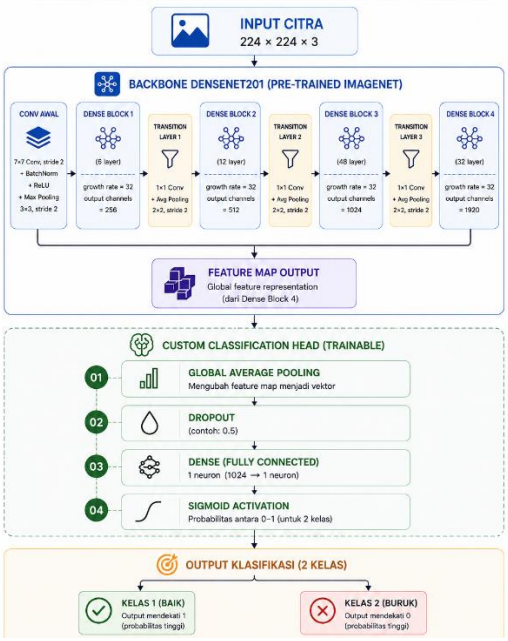
Kelas	Kualitas Bawang Merah
Baik	Segar, warna normal, tidak ada kerusakan
Buruk	Busuk, Bertunas, Berjamur, Perubahan warna

2.4 Prepocessing Data

Sebelum digunakan untuk pelatihan model DenseNet201, dataset citra bawang merah melalui tahap *preprocessing* yang mencakup penyesuaian ukuran (*resize*) menjadi 224 × 224 piksel untuk optimalisasi ekstraksi fitur, serta normalisasi nilai piksel dari rentang 0–255 menjadi 0–1 guna menstabilkan dan mempercepat proses konvergensi.

2.5 Arsitektur DenseNet201 dan Pelatihan Model

Konfigurasi Arsitektur DenseNet201: Arsitektur jaringan menggunakan *backbone* DenseNet201 dengan pendekatan *transfer learning*, terdiri atas 4 blok *bottleneck* dengan total 7.037.504 parameter *backbone* yang menghasilkan output fitur berukuran 7×7×1024. Fitur tersebut kemudian diringkas melalui lapisan Global *Average Pooling* menjadi vektor berdimensi 1024, dilanjutkan dengan lapisan Dropout yang diaktifkan untuk meminimalisir *overfitting*, serta Dense Layer 1 neuron keluaran dengan fungsi aktivasi *Sigmoid* untuk klasifikasi biner kualitas bawang merah. Total parameter keseluruhan model (termasuk *head* klasifikasi) berjumlah 7.037.504 parameter.



Gambar 2 Arsitektur model DenseNet201

Tabel 4 Konfigurasi arsitektur dan pelatihan

Parameter	Nilai
Jumlah Blok Bottleneck	4 blok
Jumlah Parameter Backbone	7.037.504
Output Fitur Backbone	7×7×1024
Global Average Pooling	1024
Dropout	Aktif
Dense Output (Sigmoid)	1 Neuron
Total Parameter (dengan Head)	7.037.504

2.6 Evaluasi Model

Evaluasi model dilakukan untuk mengukur kinerja dan validitas model DenseNet201 dalam memprediksi kelas kualitas. Matriks ini digunakan untuk mengukur seberapa efektif model dalam mengklasifikasikan data ke dalam kategori atau kelas yang benar, dengan membandingkan hasil prediksi model terhadap data aktual.

a. Akurasi

Mengukur proporsi total prediksi yang benar dari seluruh data uji:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

b. Presisi

Mengukur tingkat ketepatan model terhadap prediksi kelas positif. Presisi adalah rasio prediksi positif yang benar terhadap total kasus yang diprediksi positif:

$$Precision = \frac{TP}{TP + FP}$$

c. Recall

Mengukur kemampuan model untuk mendeteksi semua kasus positif yang sebenarnya. Recall adalah rasio prediksi positif yang benar terhadap total kasus yang sebenarnya positif:

$$Recall = \frac{TP}{TP + FN}$$

d. F1-Score

Rata-rata harmonik dari Presisi dan Recall. Metrik ini sangat berguna ketika data memiliki ketidakseimbangan kelas, karena memberikan pandangan yang lebih seimbang tentang performa model:

$$F1 - Score = 2\ x\ \frac{Precision\ x\ recall}{Precision + Recall}$$

3. HASIL DAN PEMBAHASAN

3.1 Hasil Pelatihan Model

Hasil pengujian pada data testing menunjukkan perbedaan performa antar konfigurasi batch size. Model DenseNet201 dengan batch size 32 memberikan hasil terbaik, yaitu akurasi 100% dengan loss 0,0456, serta menunjukkan kestabilan performa selama pelatihan dan validasi sehingga dipilih sebagai model terbaik. Batch size 64 juga mencapai akurasi 100%, namun dengan loss lebih tinggi (0,0763), yang mengindikasikan tingkat keyakinan prediksi yang sedikit lebih rendah. Sementara itu, batch size 16 memperoleh akurasi 98,89% dengan loss terendah (0,0356), tetapi masih terdapat beberapa kesalahan klasifikasi.

Secara umum, seluruh konfigurasi batch size menghasilkan performa klasifikasi yang baik dengan akurasi di atas 98%, dan batch size 32 memberikan keseimbangan terbaik antara akurasi, loss, dan kestabilan pelatihan. Hal ini menunjukkan bahwa pemilihan ukuran batch berpengaruh terhadap kemampuan model dalam mempelajari karakteristik citra bawang merah dan melakukan generalisasi pada data baru.

Tabel 5 Hasil Pelatihan Model

NO	Nama Model	Batch Size	Akurasi Test	Loss Test
1.	Densenet201	16	98,89%	0,0356
2.	Densenet201	32	100%	0,0456
3.	Densenet201	64	100%	0,0763

3.2 Hasil Classification Report

Hasil Classification Report model DenseNet201 pada data test set untuk ketiga konfigurasi batch size. Pada batch size 16, model memperoleh Macro Average F1-Score sebesar 0,99, sedangkan batch size 32 dan 64 mencapai nilai sempurna 1,00 pada Precision, Recall, dan F1-Score untuk kelas "baik" maupun "buruk". Hal ini menunjukkan model mampu mengklasifikasikan seluruh data testing dengan sangat akurat. Meskipun batch size 32 dan 64 menghasilkan performa klasifikasi yang setara, batch size 32 tetap dipilih sebagai konfigurasi terbaik karena memiliki nilai loss lebih rendah dan proses pelatihan yang lebih stabil.

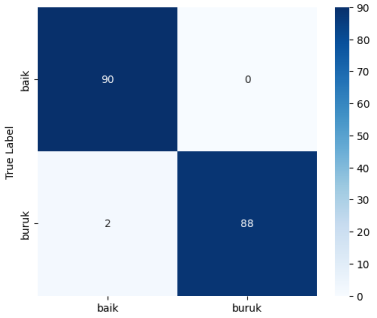
Tabel 6 Hasil Classification

Batch Size	Kelas	Precission	Recall	F1-Score	Support
16	Baik	0.98	1.00	0.99	90
	Buruk	1.00	0.98	0.99	90
	Macro Avg	**0.99**	**0.99**	**0.99**	**180**
32	Baik	1.00	1.00	1.00	90
	Buruk	1.00	1.00	1.00	90
	Macro Avg	**1.00**	**1.00**	**1.00**	**180**
64	Baik	1.00	1.00	1.00	90
	Buruk	1.00	1.00	1.00	90
	Macro Avg	**1.00**	**1.00**	**1.00**	**180**

3.3 Confusion Matrix

Confusion Matrix digunakan untuk memvisualisasikan sebaran prediksi benar dan salah pada setiap konfigurasi batch size, dengan sumbu X sebagai kelas prediksi dan sumbu Y sebagai kelas sebenarnya. Nilai pada diagonal utama menunjukkan prediksi yang benar, sedangkan nilai di luar diagonal menunjukkan kesalahan klasifikasi. Analisis dilakukan pada ketiga konfigurasi batch size untuk mengetahui pola kesalahan model DenseNet201 pada masing-masing kelas.

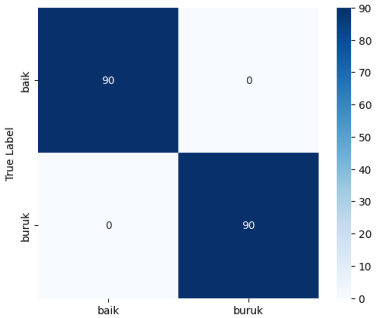
1. Batch Size 16



Gambar 3 Confusion Matrix Batch 16

Dari 180 citra data uji, model menghasilkan 2 kesalahan prediksi, yaitu 2 citra kelas "buruk" yang diprediksi sebagai kelas "baik". Seluruh 90 citra kelas "baik" berhasil diklasifikasikan dengan benar. Kesalahan kecil ini mengindikasikan adanya kemiripan visual antara sebagian citra kelas "buruk" dengan kelas "baik".

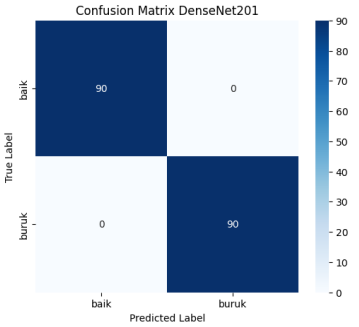
2. Batch Size 32



Gambar 4 Confusion Matrix Batch 32

Model menghasilkan klasifikasi sempurna, di mana seluruh 90 citra kelas "baik" dan 90 citra kelas "buruk" berhasil diprediksi dengan benar tanpa kesalahan. Hasil ini memperkuat evaluasi sebelumnya (precision, recall, dan F1-score sebesar 1,00 pada kedua kelas), sehingga batch size 32 dianggap sebagai konfigurasi terbaik.

3. Batch Size 64



Gambar 5 Confusion Matrix Batch 64

Model juga menghasilkan klasifikasi sempurna pada seluruh 180 citra data uji tanpa kesalahan, menunjukkan kemampuan generalisasi yang tinggi. Namun, karena nilai validation loss dan test loss lebih tinggi dibandingkan batch size 32, maka batch size 32 tetap dipilih sebagai konfigurasi terbaik dalam penelitian ini.

3.4 Pembahasan

Penelitian ini mengevaluasi performa arsitektur DenseNet201 pada tiga variasi batch size (16, 32, dan 64), di mana batch size 32 dan 64 sama-sama mencapai akurasi tertinggi sebesar 100%, sedangkan batch size 16 memperoleh akurasi 98,89% dengan 2 kesalahan klasifikasi pada kelas "buruk" dari 180 data uji, sementara batch size 32 dan 64 tidak menghasilkan kesalahan klasifikasi sama sekali; namun dari sisi loss dan pola konvergensi, batch size 16 memiliki validation loss terendah (0,0297), diikuti batch size 32 (0,0485) dan batch size 64 (0,1042), yang mengindikasikan bahwa batch size terlalu besar pada dataset terbatas dapat menurunkan efektivitas pembelajaran model. Dari sisi efisiensi komputasi, ketiga konfigurasi memiliki kompleksitas model yang sama karena menggunakan arsitektur DenseNet201 identik (total 18.323.905 parameter, ukuran model 69,90 MB, dengan hanya 1.921 parameter yang dilatih ulang pada tahap transfer learning), namun waktu pelatihan berbeda signifikan, yaitu 863 detik pada batch size 16, 1.163 detik pada batch size 32, dan 1.436 detik pada batch size 64, sedangkan waktu inferensi relatif serupa pada ketiga konfigurasi (272–294 ms per citra) sehingga tidak berdampak signifikan terhadap pengalaman pengguna pada implementasi web. Berdasarkan keseluruhan hasil evaluasi yang mencakup akurasi, loss, Classification Report, Confusion Matrix, dan efisiensi komputasi, batch size 32 dipilih sebagai konfigurasi paling optimal karena memberikan keseimbangan terbaik antara akurasi pengujian sempurna, nilai precision, recall, dan F1-score sebesar 1,00 pada kedua kelas, serta stabilitas proses pelatihan, meskipun batch size 16 unggul dari sisi efisiensi waktu komputasi, sehingga batch size 32 dinilai paling sesuai untuk diimplementasikan pada sistem klasifikasi kualitas bawang merah berbasis web.

4. KESIMPULAN

Penelitian ini telah berhasil mengimplementasikan model DenseNet201 dengan metode *transfer learning* ke dalam sebuah sistem klasifikasi bawang merah berbasis web. Sistem ini dibangun dengan memadukan framework Laravel (PHP) untuk bagian antarmuka pengguna dan Flask (Python) sebagai *backend* untuk memproses model. Secara fungsional, sistem sudah dapat berjalan dengan baik dalam menerima unggahan gambar, memproses klasifikasi secara otomatis, dan langsung menampilkan hasil prediksi beserta skor *confidence* secara *real-time* kepada pengguna. Berdasarkan pengujian, arsitektur DenseNet201 berbasis transfer learning terbukti sangat efektif dalam mengklasifikasikan kualitas bawang merah. Model ini berhasil mencapai performa sempurna dengan nilai *accuracy*, *precision*, *recall*, dan *F1-score* sebesar 100% pada data uji. Nilai *loss* yang sangat rendah (0,0456) juga mengindikasikan bahwa model memiliki kemampuan generalisasi yang sangat baik, sehingga mampu menghasilkan prediksi yang akurat dan konsisten. Penelitian ini hanya mengklasifikasikan bawang merah ke dalam dua kelas, yaitu kualitas baik dan kualitas buruk. Penelitian selanjutnya dapat mengembangkan jumlah kategori klasifikasi yang lebih rinci, misalnya berdasarkan tingkat kerusakan, ukuran, warna kulit, atau

tingkat kesegaran bawang merah sehingga hasil klasifikasi menjadi lebih informatif dan dapat melakukan perbandingan dengan arsitektur *deep learning* lain seperti EfficientNet, ConvNeXt, ResNet, Vision Transformer (ViT), maupun model terbaru lainnya untuk mengetahui arsitektur yang paling optimal dalam klasifikasi kualitas bawang merah.

DAFTAR PUSTAKA

[1] Alsyatry, H., Saragih, E. C., Rambu, F., & Mbana, L. (2024). *Analisis Faktor-Faktor Yang Mempengaruhi Permintaan Bawang Merah Di Kelurahan Matawai Kecamatan Kota Waingapu Analysis Of Factors Influencing The Demand For Shallots In Matawai Village Waingapu City District*. *20*, 875–884.

[2] Badan Pusat Statistik. (2024). Produksi Tanaman Sayuran Tahun 2023. Jakarta: Badan Pusat Statistik. Diakses dari https://www.bps.go.id/indicator/55/61/1/produksi-tanaman-sayuran.html.

[3] Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. Proceedings - 30th IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2017, 2017-January, 2261–2269. https://doi.org/10.1109/CVPR.2017.243.

[4] Kamilaris, A., & Prenafeta-Boldú, F. X. (2018). Deep learning in agriculture: A survey. Computers and Electronics in Agriculture, 147(July 2017), 70–90. https://doi.org/10.1016/j.compag.2018.02.016

[5] Lecun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436–444. https://doi.org/10.1038/nature14539.

[6] Markoulidakis, I., Rallis, I., Georgoulas, I., Kopsiaftis, G., Doulamis, A., & Doulamis, N. (2021). Multiclass Confusion Matrix Reduction Method and Its Application on Net Promoter Score Classification Problem. Technologies, 9(4), 81. https://doi.org/10.3390/technologies9040081

[7] Mocsari, E., & Stone, S. S. (2010). Colostral IgA, IgG, and IgM-IgA fractions as fluorescent antibody for the detection of the coronavirus of transmissible gastroenteritis. American Journal of Veterinary Research, 39(9), 1442–1446. https://doi.org/10.2460/ajvr.1978.39.09.1442

[8] Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. Frontiers in Plant Science, 7(September), 1–10. https://doi.org/10.3389/fpls.2016.01419

[9] otta, I. V. C., Vuillerme, N., Pham, H. H., & de Figueiredo, F. A. P. (2025). Machine learning techniques for coffee classification: a comprehensive review of scientific research. Artificial Intelligence Review, 58(1). https://doi.org/10.1007/s10462-024-11004-w

[10] Munir, R. (2024). 21-Convolutional Neutral Network. Departemen Teknik Informatika, STEI ITB. https://informatika.stei.itb.ac.id/~rinaldi.munir/Citra/2023-2024/21-CNN-2023.pdf

[11] Pada, P., Pengkajian, B., Pertanian, T., Kompleks, S. B., Gubernur, P., Barat, S., Abdul, J., & Pattanaendeng, M. (2017). Perbaikan usaha tani bawang merah dataran rendah dengan perbandingan paket teknologi petani dengan paket teknologi introduksi di Kabupaten Majene. Jurnal Agrotan, 3(1), 56–66

[12] Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. IEEE Transactions on Knowledge and Data Engineering, 22(10), 1345–1359. https://doi.org/10.1109/TKDE.2009.191

[13] Pradana, Y. A., Dewi, L. P., Rahmah, M. A., Wijanarko, A., Ishartono, N., & Kusumaningtyas, D. A. (2023). Penyelesaian Aplikasi Persamaan Diophantine dengan Algoritma Euclid. Jurnal Keilmuan Dan Keislaman, 10–18. https://doi.org/10.23917/jkk.v3i1.173

[14] Primananda, M. I., & Akbar, M. (2024). Klasifikasi Bawang Merah Asli dan Palsu Menggunakan Convolutional Neural Network. Remik: Riset Dan E-Jurnal Manajemen Informatika Komputer, 8, 864–870. http://doi.org/10.33395/remik.v8i3.13994.

[15] Ramcharan, A., Baranowski, K., McCloskey, P., Ahmed, B., Legg, J., & Hughes, D. P. (2017). Deep learning for image-based cassava disease detection. Frontiers in Plant Science, 8(October), 1–7. https://doi.org/10.3389/fpls.2017.01852

[16] Shafiq, M., & Gu, Z. (2022). Deep Residual Learning for Image Recognition: A Survey. Applied Sciences (Switzerland), 12(18), 1–43. https://doi.org/10.3390/app12188972

[17] Sofyan, S. N., & Sitorus, Z. (2025). Implementasi data mining untuk clustering produktivitas bawang merah menggunakan metode K-means. Jurnal Jatilima, 7(2), 1–9. https://doi.org/10.54209/jatilima.v7i02.1442

[18] zegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the Inception Architecture for Computer Vision. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2016-December, 2818–2826. https://doi.org/10.1109/CVPR.2016.308

[19] Tajbakhsh, N., Shin, J. Y., Gurudu, S. R., Hurst, R. T., Kendall, C. B., Gotway, M. B., & Liang, J. (2016). Convolutional Neural Networks for Medical Image Analysis: Full Training or Fine Tuning? IEEE Transactions on Medical Imaging, 35(5), 1299–1312. https://doi.org/10.1109/TMI.2016.2535302

[20] Takamitsu, Y., & Orita, Y. (1978). Effect of glomerular change on the electrolyte reabsorption of the renal tubule in glomerulonephritis (author's transl). Japanese Journal of Nephrology, 20(11), 1221–1227